UNIVERSIDADE PRESBITERIANA MACKENZIE

Curso de Tecnologia em Banco de Dados
Disciplina: Projeto Aplicado II

RELATÓRIO TÉCNICO INTEGRADO

Etapa A1 e Etapa A2 – Definição do Método Analítico

Alunos	Felipe Graciano • Diogo Ferreira • André Cavina
Professor	Felipe Albino
Projeto	Análise textual de restaurantes do iFood com NLP e Aprendizado de Máquina
Base de dados	iFood Restaurants Data (Kaggle)

Documento consolidado com alinhamento entre a Etapa 1 e a Etapa 2, revisado para coerência metodológica e aderência à rubrica avaliativa.

Apresentação

Este documento consolida a Etapa A1 e a Etapa A2 do Projeto Aplicado II em um único relatório técnico, com alinhamento explícito entre escopo, problema, base de dados e método analítico. A reestruturação foi realizada para garantir coerência entre o trabalho já concluído, a continuidade metodológica exigida pela disciplina e os critérios de avaliação apresentados na rubrica.

A tabela a seguir demonstra, de forma objetiva, como o relatório integrado atende aos critérios centrais da rubrica de avaliação da Etapa A2 e como a Etapa A1 foi reestruturada para garantir continuidade lógica com a Etapa A2.

Critério da rubrica	Como foi atendido no relatório	Seção correspondente
Definição da linguagem de programação	A linguagem Python foi justificada pelas necessidades do projeto e as bibliotecas foram definidas objetivamente, sem deixar itens em aberto.	3.1
Análise exploratória da base de dados	A base foi caracterizada, os campos relevantes foram delimitados e a EDA foi organizada com foco em padrões textuais e variáveis de apoio.	3.2

Tratamento da base de dados	O pipeline de limpeza, normalização, exclusão de casos inadequados e vetorização foi descrito de forma sequencial e técnica.	3.3
Bases teóricas dos métodos	Foram apresentados os fundamentos de NLP, TF-IDF, classificação supervisionada e Regressão Logística, com justificativa da escolha.	3.4
Definição de como será calculada a acurácia	A métrica principal foi definida, acompanhada de métricas complementares para avaliação mais robusta.	3.5

1. Etapa A1 – Kick-off (revisada para continuidade metodológica)

A Etapa A1 foi mantida em seus elementos corretos, definição do contexto organizacional, escolha do problema de negócio, seleção da base de dados e criação do repositório, mas foi reestruturada para eliminar ambiguidades e preparar explicitamente a evolução para a Etapa A2. Assim, o presente relatório não trata a Etapa A1 e a Etapa A2 como entregas isoladas, mas como partes sequenciais de um único produto analítico.

1.1 Contexto do projeto

O projeto está inserido em uma empresa fictícia denominada Delivery Insights Analytics, uma consultoria especializada em inteligência de mercado para plataformas de food delivery. O foco do projeto é gerar valor analítico a partir de dados de restaurantes, com ênfase em descoberta de padrões textuais capazes de apoiar busca, recomendação e compreensão de perfis de estabelecimentos.

1.2 Base de dados selecionada

A base escolhida é o conjunto iFood Restaurants Data, disponibilizado no Kaggle, contendo registros de restaurantes brasileiros em formato tabular. O conjunto reúne variáveis textuais e numéricas, o que o torna adequado para uma proposta interdisciplinar que combina engenharia de dados, processamento de linguagem natural e aprendizado de máquina.

- Campos textuais centrais para o projeto: name, category e tags.
- Campo numérico de apoio para avaliação supervisionada: rating.
- Uso principal da base: transformação de informações textuais em atributos analíticos para modelagem.

(disponível em: Base de Dados - Kaggle).

1.3 Problema analítico definido no kick-off

No kick-off, o grupo delimitou que o projeto deveria obrigatoriamente trabalhar com texto. A proposta inicial consistiu em analisar nomes, categorias e segmentos de restaurantes para identificar padrões relevantes ao negócio. Essa definição foi preservada. O ponto que exigiu ajuste foi a formulação do método, originalmente aberta entre modelo preditivo e clusterização. Para garantir rigor metodológico e coerência com a rubrica, essa ambiguidade foi resolvida na Etapa 2 em favor de um modelo supervisionado de classificação textual.

1.4 Objetivo geral consolidado

Desenvolver um produto analítico baseado em Processamento de Linguagem Natural e Aprendizado de Máquina para analisar atributos textuais de restaurantes do iFood e identificar padrões associados à avaliação dos estabelecimentos, contribuindo para aplicações de busca, categorização e recomendação em plataformas de delivery.

1.5 Metas específicas revisadas

1. Realizar análise exploratória da base com foco em estrutura, qualidade dos dados, padrões textuais e distribuição da variável de avaliação.
2. Preparar e tratar os campos textuais por meio de limpeza, normalização e vetorização.
3. Aplicar um método supervisionado de classificação textual compatível com a base e com os objetivos do projeto.
4. Avaliar o desempenho do modelo com acurácia e métricas complementares.
5. Produzir documentação técnica e narrativa analítica coerentes com as etapas do projeto.

1.6 Entregáveis da Etapa A1 que permanecem válidos

- formação do grupo e identificação dos participantes;
- definição da organização fictícia e do problema de negócio;
- escolha da base iFood Restaurants Data;
- criação do repositório GitHub para trabalho colaborativo.

2. Alinhamento explícito entre a Etapa A1 e a Etapa A2

Para atender ao pedido de continuidade explícita, esta seção demonstra como cada definição do kickoff foi mantida, refinada ou corrigida na Etapa 2. O objetivo é assegurar unidade entre o escopo inicial e a metodologia analítica final.

Elemento da Etapa 1	Ajuste de continuidade na Etapa 2	Resultado harmônico
Foco obrigatório em texto	Foi preservado e transformado em pipeline de NLP com campos name, category e tags.	O projeto mantém identidade temática e técnica clara.
Uso da base do iFood	Foi mantido, com recorte objetivo dos atributos relevantes à modelagem.	A base segue sendo a mesma, porém agora com uso metodológico definido.
Proposta ampla de “modelo preditivo ou clusterização”	Foi corrigida para classificação supervisionada textual.	Elimina ambiguidade e fortalece a justificativa metodológica.
Meta de avaliar desempenho	Foi detalhada com definição de acurácia, precisão, recall, F1score e matriz de confusão.	A avaliação deixa de ser genérica e passa a ser tecnicamente mensurável.

Criação do repositório GitHub	Foi mantida como base da execução colaborativa e da organização do projeto.	A documentação, notebooks e scripts passam a refletir a mesma linha metodológica.

3. Etapa A2 – Definição do método analítico

A Etapa 2 foi estruturada segundo o roteiro exigido pela disciplina: definição da linguagem e bibliotecas, análise exploratória da base, tratamento da base de dados, bases teóricas do método e

definição de como será calculada a acurácia. O texto a seguir já está redigido para atender diretamente aos critérios da rubrica.

3.1 Definição da linguagem de programação usada no projeto

A linguagem adotada no projeto é Python. A escolha é apropriada porque o problema envolve manipulação de dados tabulares, processamento de texto, vetorização, treinamento de modelos supervisionados e avaliação estatística, atividades para as quais Python oferece ecossistema maduro e amplamente utilizado na área de Ciência de Dados.

As bibliotecas definidas para o projeto são: pandas, numpy, matplotlib, seaborn, nltk, scikit-learn, unidecode e joblib. Essa definição objetiva elimina lacunas e justifica tecnicamente a escolha da linguagem segundo as necessidades do projeto.

3.2 Análise exploratória da base de dados escolhida

A análise exploratória da base foi planejada para não se limitar à descrição superficial do arquivo. Ela se concentra na estrutura dos dados, na qualidade das informações e nos padrões textuais relevantes ao objetivo analítico.

- caracterização estrutural da base, com identificação de colunas, tipos de dados, registros duplicados e valores ausentes;
- inspeção dos campos textuais name, category e tags, que constituem o núcleo da análise de NLP;
- observação da distribuição da variável rating, que servirá de base para o problema supervisionado;
- levantamento de frequências de categorias e termos recorrentes;
- análise de tamanho dos textos e impacto da limpeza sobre os tokens mais frequentes.

Com isso, a EDA deixa de ser apenas descritiva e passa a servir de fundamento para a modelagem, evidenciando padrões, tendências e peculiaridades da base, como exige a rubrica.

3.3 Tratamento da base de dados (preparação e treinamento)

O tratamento da base foi definido como um pipeline encadeado, com foco em qualidade analítica e reprodutibilidade. As etapas são:

6. seleção das variáveis name, category, tags e rating;
7. padronização textual com conversão para minúsculas, remoção de acentos, pontuação, caracteres especiais e espaços redundantes;
8. remoção de stopwords em português e unificação dos campos textuais em uma única representação;
9. tratamento dos registros sem nota ou inadequados ao problema supervisionado, evitando confundir ausência de avaliação com baixa avaliação;
10. vetorização dos textos por TF-IDF, com uso de unigramas e possibilidade de bigramas;

11. divisão da base em treino e teste, preferencialmente em proporção 80/20, com estratificação das classes.

Essa preparação demonstra integração entre limpeza, transformação e preparação para treinamento, o que atende diretamente ao critério da rubrica sobre tratamento eficaz da base de dados.

3.4 Definição e descrição das bases teóricas dos métodos

O método analítico principal adotado no projeto é a classificação supervisionada de textos, utilizando vetorização TF-IDF e Regressão Logística. A escolha se apoia nos seguintes fundamentos teóricos:

Processamento de Linguagem Natural (NLP): permite transformar linguagem natural em representações tratáveis computacionalmente, tornando viável a análise estatística dos textos dos restaurantes.

TF-IDF: atribui pesos aos termos de acordo com sua relevância relativa nos documentos, destacando palavras mais discriminativas para a classificação.

Classificação supervisionada: parte de exemplos rotulados e busca aprender padrões que permitam prever a classe de novos casos.
Regressão Logística: foi escolhida por ser interpretável, eficiente para dados esparsos e adequada como linha de base em problemas de classificação textual.

A mudança em relação à formulação inicial do kick-off não altera o propósito do projeto; ao contrário, o fortalece. O foco continua sendo entender padrões textuais em restaurantes do iFood, mas agora com método definido e justificativa conceitual robusta.

3.5 Definição e descrição de como será calculada a acurácia

A avaliação do modelo será realizada com base na comparação entre as classes previstas e as classes reais no conjunto de teste. A métrica principal será a acurácia, calculada como a razão entre o número de previsões corretas e o total de previsões realizadas.

Acurácia = número de previsões corretas / número total de previsões

Para evitar uma avaliação superficial, também serão apresentadas métricas complementares: precisão, recall, F1-score e matriz de confusão. Essas métricas são importantes para qualificar o desempenho do modelo, especialmente se houver desbalanceamento entre as classes.

Dessa forma, o relatório não apenas informa que a acurácia será usada, mas descreve claramente como ela será calculada e em que contexto interpretativo ela será analisada, atendendo ao nível mais alto da rubrica.

3.6 Síntese metodológica consolidada

Em síntese, a Etapa 2 fecha metodologicamente o projeto como uma solução de classificação supervisionada de textos aplicada à base iFood Restaurants Data. O modelo utilizará os campos name, category e tags, vetorizados por TF-IDF, para prever classes derivadas da avaliação dos restaurantes por meio de Regressão Logística. Essa formulação preserva a ideia central do kick-off e transforma o escopo inicial em um produto analítico tecnicamente consistente.

3.7 Link para o Repositório no GitHub

O versionamento do código, os datasets tratados e a documentação do projeto estarão centralizados no seguinte repositório público:

Link: Repositório GitHub

4. Objetivo do Projeto

No mercado de delivery, a reputação de um restaurante é fundamental. Enquanto muitas análises focam em métricas puramente quantitativas, como tempo de entrega ou preço, o objetivo desta etapa é analisar a semântica por trás do sucesso desses estabelecimentos. Desenvolvemos um modelo supervisionado de classificação de textos para identificar padrões na forma como os restaurantes se apresentam no aplicativo. Queremos entender se o nome, a categoria e as tags utilizadas por um restaurante possuem relação direta com a sua avaliação final.

4.1 Base de Dados

A base principal do nosso projeto é o dataset público iFood Restaurants Data, extraído do Kaggle. Para garantir o volume de dados necessário para um modelo de Processamento de Linguagem Natural (NLP), escolhemos o arquivo de fevereiro de 2021 para o treinamento, que conta com 406.399 registros e 14 colunas, oferecendo a densidade textual ideal para a análise. A base de novembro de 2020 servirá apenas como apoio comparativo.

4.2 Linguagem e Bibliotecas

Todo o desenvolvimento foi feito em Python, utilizando bibliotecas clássicas e consolidadas:

- Manipulação de dados: *pandas* e *numpy*.

- Visualização: *matplotlib* e *seaborn*.
- Processamento de Linguagem Natural (NLP): *nltk* e *unidecode* para limpeza e padronização dos textos.
- Modelagem: *scikit-learn* para o pipeline de vetorização, treinamento e métricas, além do *joblib* para salvar o modelo treinado.

4.3 Metodologia Escolhida

Optamos por uma abordagem direta e bem fundamentada para a classificação de textos: TF-IDF combinado com Regressão Logística. Essa escolha traz vantagens claras:

1. Define um método analítico objetivo.

1. O TF-IDF vetoriza os textos dando o peso correto às palavras que realmente diferenciam um restaurante, penalizando termos genéricos.
2. A Regressão Logística é um modelo altamente interpretável. Após o treinamento, podemos extrair o peso de cada palavra e entender quais termos influenciam a nota de forma positiva ou negativa.

4.4 Estratégia Analítica

4.4.1 Análise Exploratória (EDA)

A base passou por uma análise para tratamento de nulos, duplicidades, distribuição das notas (rating) e investigação de termos frequentes.

4.4.2 Tratamento dos Textos

O pipeline incluiu remoção de ruídos (acentos e stopwords), padronização em minúsculas, concatenação das colunas name, category e tags em um único texto, seguido de vetorização por TF-IDF e separação estratificada entre treino e teste.

4.4.3 Variável-alvo

Transformamos o problema contínuo em classificação binária: excluímos notas zero e definimos restaurantes com nota ≥ 4,5 como "alta_avaliacao", e os demais na categoria oposta.

4.5 Métricas de Avaliação

Para garantir que o modelo seja avaliado de forma justa, a acurácia foi definida como a métrica principal. Contudo, para uma visão completa, também avaliamos a precisão, o recall, o F1-score e a matriz de confusão.

4.6 Consolidação dos Resultados e Métricas de Desempenho

Após a vetorização dos textos (TF-IDF) e o treinamento da Regressão Logística, consolidamos os resultados aplicando o modelo à base de teste. O objetivo preditivo foi alcançado com as seguintes métricas de desempenho:

- Acurácia global: *62,80%*.

- Precisão (precision): *61,71%*.
- Revocação (recall): *63,10%*.
- F1-score: *0,6124*.

Matriz de confusão: o modelo previu corretamente 18.824 restaurantes de alta avaliação e 9.717 restaurantes da classe demais.

Figura 1 – Matriz de confusão. Fonte: elaborado pelo autor.

Insights semânticos extraídos: por meio dos pesos da Regressão Logística, identificamos quais termos impactam as avaliações. Termos como "super restaurant" e "restaurant wrapped" possuem forte correlação positiva com a categoria "alta avaliação". Em contrapartida, palavras como "madero" e "rapi" demonstraram correlação negativa, reduzindo as predições.

4.7 Produto Gerado e Modelo de Negócios

Com base nos resultados acima, nossa empresa, a Delivery Insights Analytics, estruturou um produto de inteligência de mercado chamado *Semantic Menu Optimizer*.

O produto: trata-se de um motor de recomendação textual voltado para empreendedores do ramo de *food delivery*. O cliente insere o nome do restaurante, a categoria e as tags que deseja usar no iFood. O algoritmo processa esse texto,

prevê a probabilidade de obter notas ≥ 4,5 e sugere correções léxicas (remover termos nocivos e incluir palavras-chave de alto rendimento).

Modelo de negócios (monetização):

- **B2B para restaurantes (SaaS):** venda de assinaturas para consultorias de rebranding ou para novos restaurantes que desejam entrar no aplicativo já com um posicionamento de palavras otimizado.

- **B2B para plataformas de delivery:** licenciamento da nossa API para a própria plataforma, funcionando como um assistente na tela de cadastro do parceiro, ajudando a limpar e padronizar o sistema de busca interno do app.

4.8 Esboço do Storytelling (preparação para a Etapa 4)

Para a apresentação final em formato de vídeo exigida na Etapa 4, utilizaremos a técnica de *data storytelling* estruturada na seguinte jornada:

1. **O cenário (dor do negócio):** abrir questionando a dificuldade de se destacar em um app com milhares de opções: "As palavras que você escolhe para descrever seu negócio no iFood determinam sua nota?".

1. **O desenvolvimento (a jornada dos dados):** mostrar de forma acessível como limpamos mais de 406 mil registros, ensinando a máquina a entender a semântica de nomes e categorias via NLP e TF-IDF.
2. **O clímax (as descobertas):** apresentar os resultados do algoritmo e um painel com "as palavras que garantem o sucesso" versus "as palavras que derrubam a avaliação", incluindo a acurácia obtida.
3. **A conclusão (geração de valor):** fechar apresentando o *Semantic Menu Optimizer*, mostrando como a Delivery Insights Analytics converte algoritmos em valor para restaurantes e plataformas.

4.9 Estrutura do Repositório e Execução

O projeto foi organizado de forma modular para facilitar a execução e a avaliação do código:

```
plaintext ├── data/ (raw/ e processed/) ├── notebooks/
(Documentação da EDA e testes de modelagem) ├── src/
(Scripts Python modulares: config, preparação, treino e
avaliação) ├── docs/ (Relatórios e metodologias da Etapa A2)
└── requirements.txt
```

4.10 Como Executar

1. Instale as dependências: *pip install -r requirements.txt*.

1. Baixe os arquivos do Kaggle e coloque-os na pasta *data/raw/*.
2. Execute o pipeline em sequência:
    1. *python -m src.data_preparation*
    2. *python -m src.train_model*
    3. *python -m src.evaluate_model*

5. Conclusão

O relatório integrado evidencia que a Etapa A1 e a Etapa A2 não são documentos independentes, mas partes de uma mesma construção metodológica. A Etapa A1 define o problema, o contexto e a base; a Etapa A2 transforma essas definições em um método analítico objetivo, justificável e mensurável.

Com a presente reestruturação, o projeto ganha coerência interna, continuidade explícita entre as etapas e aderência direta aos critérios avaliativos. O que estava adequado foi preservado; o que apresentava ambiguidade ou insuficiência foi ajustado para que o conjunto do trabalho fique harmônico, tecnicamente claro e alinhado ao padrão de excelência esperado pela rubrica.

Dessa forma, o projeto consolida a transição entre o rigor estatístico e a aplicabilidade de mercado. A validação técnica obtida via Processamento de Linguagem Natural (NLP) não apenas confirma a viabilidade do modelo preditivo, mas fundamenta o lançamento do Semantic Menu Optimizer como uma solução real de Business Intelligence. O caminho está agora pavimentado para a Etapa Final (Storytelling), onde a complexidade dos dados será traduzida em uma narrativa estratégica, demonstrando como a Delivery Insights Analytics utiliza a ciência de dados para converter padrões semânticos em vantagem competitiva e sucesso reputacional no ecossistema de food delivery.